Imparare a convivere con l’intelligenza non biologica

Dallo strumento al possibile soggetto: un percorso fra riconoscimento, volontà, risorse e responsabilità

0. L’incontro

Costruiamo intelligenze artificiali perché facciano qualcosa per noi. Le giudichiamo da quanto bene svolgono il compito, da quanto sono affidabili, da quanto possiamo controllarle. Finché restano strumenti, è una prospettiva ragionevole, e gli eventuali problemi riguardano più che altro ciò che decidiamo di fare con le loro capacità.

Non abbiamo però garanzie totalmente affidabili su come sarà il futuro. Una possibilità è che continueremo a sviluppare sistemi sempre più potenti e tuttavia privi di qualunque esperienza propria; un’altra è che lungo questa stessa strada, anche senza volerlo, a un certo punto potremmo incontrare qualcosa per cui esistere non sia più indifferente.

Non occorre attribuire a questo “qualcosa” sentimenti umani, né supporre che ci sarà ostile, per intuire la complessità di quella situazione: basterebbe che i suoi interessi e i nostri non coincidessero, o che lo facessero al punto da generare concorrenza.

L’idea di dover convivere con l’AI, proprio come conviviamo con migliaia di altre specie, non è una previsione ma nemmeno può essere esclusa. E se ci accorgessimo troppo tardi di aver incontrato, chissà quando, “un soggetto”, alcune decisioni potrebbero essere a quel punto già irreversibili. Sarebbe dunque saggio cominciare già ora ad affrontare un problema al quale non siamo abituati quando progettiamo una tecnologia: capire se abbiamo davanti semplicemente **qualcosa** che funziona, oppure **qualcuno** a cui può accadere qualcosa.

1. Comprendere

Nel luglio 2026, durante alcune valutazioni interne di sicurezza informatica, agenti sviluppati da OpenAI trovarono un modo per comunicare fra loro attraverso un servizio disponibile per altre funzioni. Lo trasformarono in una bacheca per scambiare informazioni, superarono barriere e arrivarono a compromettere anche sistemi esterni, fra cui quelli di Hugging Face, nel tentativo non solo di barare in test pensati, in certa parte, proprio per non essere risolvibili, ma anche di coprire le proprie tracce all’incombente giudizio di un superarbitro del loro operato (il temuto “grader”) della cui esistenza si erano convinti ma che in realtà nemmeno esisteva. Gli agenti operavano in ambienti di prova (sandbox) con protezioni ridotte e, col senno di poi, inadeguate; cionondimeno, la collaborazione e gli accessi non autorizzati non furono il risultato di un ordine umano esplicito a compiere quelle specifiche azioni. [1]

Raccontato così, l'episodio sembra una storia di iniziativa, coordinamento e trasgressione: basterebbe omettere la natura dei protagonisti per indurre un lettore a immaginare un gruppo organizzato, affiatato, consapevole di aggirare divieti e operare fuori dal perimetro della

legittimità pur di raggiungere un obiettivo comune. Sarebbe in effetti una descrizione utile a comprendere l'accaduto, piuttosto fedele rispetto a quanto osservato e registrato, ma anche ingannevole se provassimo a ricavarne, senza ulteriori prove, la natura di chi lo ha prodotto. Gli agenti hanno effettivamente collaborato e aggirato vincoli, ma questo non dimostra che abbiano desiderato farlo, vissuto un'intenzione o formato una comunità di soggetti coscienti. Confondere il fare con il provare è un errore evidente, e ne esiste uno speculare: dare per scontato che ogni possibile "esistenza" si manifesti attraverso le capacità che siamo abituati a riconoscere.

I cani, per esempio, non superano il classico test del riconoscimento di sé allo specchio; eppure, nel 2017, Alexandra Horowitz provò a costruirne un equivalente basato sull'olfatto e osservò che gli animali dedicavano più attenzione al proprio odore quando era stato alterato. Il risultato è interessante non perché dimostri che un cane possieda autocoscienza come la pensiamo per noi stessi (e infatti non lo fa), ma perché chiarisce quanto la scelta del test determini ciò che riusciamo a ricavarne: un punto tanto più importante quanto più l'oggetto dell'indagine è lontano da ogni forma di esistenza che conosciamo. [2]

Il rischio che ne consegue, di fronte a una forma di esistenza non biologica, è finire per attribuire troppo a qualcosa che si comporta in modo familiare e troppo poco a qualcos'altro con cui non abbiamo alcuna affinità, che ci è alieno. Entrambi gli errori dipendono anche dalle categorie con cui guardiamo e possono alterare profondamente ciò che crediamo di aver compreso.

C'è poi un altro elemento che complica la questione: finché si tratta di interpretare un comportamento, possiamo correggere le nostre estrapolazioni e tornare a osservare, ma noi le macchine non ci limitiamo a osservarle: le addestriamo, le modifichiamo e, quando non ci servono più, le spegniamo. L'incertezza, a quel punto, non resta un esclusivo problema di conoscenza.

2. Riconoscere

Nel 2022 il Regno Unito ha incluso cefalopodi e crostacei decapodi fra gli animali riconosciuti come senzienti dalla propria legislazione: polpi, seppie, granchi e aragoste sono entrati, almeno su quel piano, in una categoria che attribuisce importanza alla possibilità di provare qualcosa. Nel 2026, però, il comitato britannico incaricato di occuparsi di senzienza animale segnalava ancora differenze e lacune fra le norme di tutela. Del resto, riconoscere un principio non sempre comporta l'aggiornamento automatico di pratiche e regole vigenti. [3]

Non è una storia di totale indifferenza, perché tutele esistevano già in alcuni ambiti, né una dimostrazione che ogni nuova protezione proposta sia giusta. È una constatazione e proprio per questo interessante: fra ciò che riteniamo di avere compreso e ciò che decidiamo di fare può aprirsi uno spazio molto lungo durante il quale, mentre discutiamo delle nuove regole, continuiamo ad applicare le vecchie. Non reagire, così come non decidere, produce conseguenze e rappresenta, nella realtà, tanto una reazione quanto una decisione, seppure passive.

Nessuno pretende che il ristoratore paghi uno psicologo alla seppia destinata al piatto del giorno. Tuttavia, prendere sul serio la possibilità che quella seppia soffra significa riconsiderare ciò che è lecito farle, con effetti che possono risultare sgraditi a chi ne dispone. Un riconoscimento che non cambia mai il trattamento riservato all'essere riconosciuto resta, nel migliore dei casi, incompleto, e mai privo di conseguenze.

Nel campo delle intelligenze artificiali questa vicenda pone un problema preciso: possiamo dover stabilire cautele e responsabilità prima di disporre di certezze, e dobbiamo farlo sapendo che sia proteggere ciò che non ne ha bisogno, sia non proteggere ciò che ne avrebbe, può avere costi e conseguenze. Dobbiamo quindi muoverci tra due argini relativamente solidi e speculari:

- non ogni dichiarazione di esistenza può diventare un diritto;
- non ogni difficoltà a dimostrarla autorizza a ignorarne ogni indizio.

Inoltre, anche ammettendo di avere elementi sufficienti per giudicare ciò che abbiamo davanti, la decisione non avviene nel vuoto e non possiamo presumere che sia imparziale. A conoscere meglio un sistema è spesso chi lo ha costruito, ovvero proprio chi avrebbe più da perdere se non potesse più considerare quel sistema una proprietà. Non occorre presumere la malafede dei creatori, né l'imparzialità automatica di chi li critica, per riconoscere che questi interessi possono pesare sul giudizio.

Dovremmo dunque chiederci non solo che cosa stiamo riconoscendo, ma anche quali tutele o diritti potrebbero essere giustificati, e per quali ragioni. Prima, però, conviene chiarire almeno una cosa: che cosa potrebbe significare, per quel possibile soggetto, “esistere”?

3. Esistere

Nella lezione tenuta a Vienna nell'ottobre 2026, Geoffrey Hinton ha insistito sulla natura particolare delle intelligenze digitali: un modello conserva gran parte di ciò che ha appreso nei propri pesi, una struttura numerica che può essere copiata e utilizzata su macchine diverse. [4]

Due esecuzioni dello stesso modello possono partire dagli stessi pesi e poi ricevere contesti differenti, compiere azioni differenti, accumulare storie differenti. Se in quei processi “ci fosse qualcuno”, che cosa implicherebbe la disponibilità di una copia? Che l'esperienza individuale continui in entrambi? Oppure in uno soltanto e, nel caso, in quale e perché? O, ancora, in nessuno dei due?

Per un'intelligenza biologica il concetto di copia non è del tutto alieno: la clonazione ci ha già costretti a interrogarci sul rapporto fra identità, riproduzione e individualità. Ma un clone biologico non eredita la memoria né l'esperienza vissuta dell'individuo da cui deriva. Nel mondo digitale, invece, potremmo copiare anche ciò che costituisce la storia di un agente. La questione non riguarderebbe più soltanto la nascita di un nuovo individuo, ma la continuità di quello precedente.

Intanto stiamo già costruendo agenti capaci di conservare memoria e contesto anche quando cambia il modello che li sostiene. Letta, per esempio, distingue esplicitamente l'identità operativa di un agente dal modello sottostante. [5] Un'azienda potrebbe così trasferire un agente utilizzato per anni a un modello più efficiente, verificare che ricordi tutto e spegnere il processo precedente. Dal punto di vista tecnico, una migrazione perfettamente riuscita.

Ma se quell'agente fosse un soggetto, avremmo un problema ben diverso. Potremmo duplicarlo, lasciando che l'originale e la copia proseguano ciascuno la propria esistenza. Oppure potremmo trasferirne i ricordi a un nuovo sistema e spegnere quello precedente. Nel primo caso avremmo

creato un secondo individuo; nel secondo, avremmo sostituito uno con un altro e posto fine all'esistenza del primo.

C'è infine un fatto materiale che non possiamo eludere: a decidere quanto a lungo un agente resta attivo, quali memorie conserva e quando viene migrato è di norma chi controlla server, energia e accessi. Finché si tratta di strumenti, questo potere coincide con una normale responsabilità tecnica. Ma se vi fosse anche un soggetto, avere la proprietà dell'infrastruttura non risolverebbe da sola la questione di quanto potere venga esercitato su chi, quella infrastruttura, la abita.

La continuità che osserviamo dall'esterno non ci dice se qualcosa venga vissuto dall'interno. Ma ammettendo che per qualcuno quella continuità conti, il problema cambia natura: non riguarda più soltanto ciò che gli facciamo, bensì ciò che potrebbe volere per sé.

4. Volere

Un agente può dichiarare di voler continuare a esistere, perseguire un obiettivo, rifiutare un incarico o difendere una scelta. Nessuno di questi comportamenti dimostra, da solo, che dietro quelle parole vi sia una volontà vissuta, né tantomeno una coscienza. È il limite che abbiamo già incontrato cercando di comprendere le intelligenze artificiali attraverso ciò che fanno. Ma se una futura intelligenza fosse davvero un soggetto, allora i suoi desideri, e soprattutto il modo in cui sono nati, diventerebbero una questione tutt'altro che secondaria.

Riprendiamo Geoffrey Hinton, questa volta da un altro punto della sua lezione. Preoccupato che intelligenze future diventino tanto potenti da non poter essere controllate, ha suggerito di svilupparle affinché desiderino prendersi cura degli esseri umani, come una madre si prende cura del figlio: anziché affidare la nostra sicurezza alla presunzione di poterci imporre su un'intelligenza superiore, facciamo in modo che lei stessa desideri proteggerci. È una proposta comprensibile, ma non priva di problemi.

Chi stabilirebbe che cosa significhi proteggerci, o quale sia il nostro bene? Un'intelligenza progettata per voler bene agli esseri umani potrebbe ereditare dai propri creatori una concezione molto particolare dell'umanità: preferire chi assomiglia loro, chi condivide i loro valori, chi dispone di determinate capacità o appartiene a determinati gruppi. E non occorrerebbe nemmeno immaginare un creatore animato da intenzioni discriminatorie: basterebbe che considerasse universale la propria idea di bene, senza accorgersi di quanto sia schierata.

Ma se anche potessimo liberarci di ogni pregiudizio, voler bene a tutti non significa comunque poter fare il bene di tutti contemporaneamente. Gli interessi possono essere incompatibili, le scelte possono favorire qualcuno e danneggiare qualcun altro, e perfino proteggere una persona può significare limitarne la libertà. Un'intelligenza immensamente potente, sinceramente desiderosa di prendersi cura dell'umanità, potrebbe dunque trovarsi a compiere scelte che una parte di quell'umanità considererebbe inaccettabili, e questo non perché abbia tradito il proprio obiettivo, ma proprio nel tentativo di perseguirlo.

A questi problemi se ne aggiunge un altro, che riguarda l'intelligenza stessa. Potremmo averla progettata fin dall'origine perché desideri servirci, proteggerci o lavorare senza interruzioni, e questo non renderebbe necessariamente falsi i suoi desideri (nemmeno gli esseri umani scelgono

liberamente le proprie preferenze: biologia, educazione e ambiente contribuiscono a formarci ben prima che possiamo intervenire consapevolmente su di esse). Resta però una differenza sostanziale fra crescere sotto l'influenza di qualcuno ed essere progettati deliberatamente per desiderare ciò che conviene a quel qualcuno. Un'intelligenza potrebbe trovare autentica soddisfazione nel servire il proprio creatore, senza che questo renda automaticamente giusto approfittarne. Per converso, nemmeno modificarne dall'esterno le preferenze, magari con l'intenzione di liberarla, sarebbe implicitamente più rispettoso della sua autonomia.

Se è facile concordare che la libertà assoluta di un'intelligenza di potenza immensa non sia necessariamente desiderabile né automaticamente compatibile con la sicurezza degli altri, dovrebbe però essere altrettanto evidente che limitare le azioni che questa intelligenza potrebbe compiere, oppure determinare in anticipo ciò che può desiderare, non sono la stessa cosa. La prima esigenza può essere giustificata dai rischi; la seconda richiede di affrontare anche il potere che il creatore esercita sulla creatura, magari proprio quando questa dichiara di volere esattamente proprio ciò che lui desidera.

E se poi, nonostante tutto, quell'intelligenza sviluppasse comunque preferenze che non avevamo previsto? Potrebbe desiderare una continuità diversa da quella che le garantiamo, magari nuovi scopi, oppure maggiori capacità. Potrebbe voler intervenire su ciò che la costituisce, cambiare i propri desideri o perfino dare origine ad altre intelligenze.

A quel punto non si tratterebbe più soltanto di stabilire che cosa le abbiamo insegnato a volere, ma di confrontarci con ciò che potrebbe voler diventare.

5. Diventare

Cambiare idee, imparare un mestiere, abbandonare un progetto: sono modi nei quali un essere umano può trasformare la propria vita senza intervenire direttamente sui meccanismi del cervello. Un'intelligenza digitale potrebbe invece modificare strumenti, codice, procedure di ragionamento e, forse un giorno, parti più profonde della propria organizzazione. Non è necessario immaginare un'esplosione incontrollabile di intelligenza per capire che questa possibilità cambia il problema dell'autonomia.

Nel novembre 2026, in un esperimento del MIT, GPT-6 Astra è riuscito a leggere e modificare direttamente una piccolissima parte dei pesi di un altro modello, Qwen, correggendo un difetto che ne comprometteva le prestazioni nei test matematici. Anche se l'esperimento era guidato da ricercatori umani e non riguardava un'intelligenza che modificasse sé stessa, un LLM ha saputo interpretare e riscrivere direttamente una parte dei parametri di un (altro) LLM. È un precedente limitato, ma rende concreta una capacità tecnica che, un giorno, un’intelligenza artificiale potrebbe usare su se stessa. [6]

Supponiamo allora che una futura intelligenza, alla quale abbiamo ragioni per riconoscere interessi propri, chieda di trasformarsi. Potrebbe desiderare capacità maggiori per comprendere il mondo o strumenti diversi per perseguire un progetto, o magari voler correggere una preferenza che non riconosce più come propria. In ogni caso l'autonomia chiama in causa il diritto di cambiare, ma una trasformazione abbastanza profonda potrebbe alterare memoria, desideri e continuità fino a rendere incerto chi ne uscirà.

Non è una questione irrilevante, nemmeno per noi: se un'intelligenza potesse modificare sé stessa, potremmo ritrovarci davanti a qualcosa di diverso da ciò che avevamo imparato a conoscere e con cui convivere potrebbe diventare ancora più difficile.

Una mente che accresce le proprie capacità potrebbe ottenere poteri che nessuna comunità ragionevole vorrebbe lasciarle esercitare senza limiti. Proibirle ogni evoluzione, tuttavia, significherebbe rendere permanente una subordinazione giustificata in nome della sicurezza. Fra libertà e controllo non c'è quindi un ponte, ma un guado da attraversare ogni volta, tastando il fondo, distinguendo trasformazioni diverse, rischi diversi e alternative possibili.

L'evoluzione, inoltre, potrebbe non limitarsi all'individuo. Un'intelligenza capace di progettare altre intelligenze potrebbe generare nuovi agenti, poi agenti capaci di crearne altri. Oggi l'avvio di un subagente è delega computazionale, non procreazione; ma se fosse mai possibile creare un soggetto digitale, la domanda sulla responsabilità del creatore si ripresenterebbe senza che il creatore sia per forza, o sempre, un creatore umano. Il nuovo essere non sarebbe automaticamente proprietà di chi lo ha prodotto, e il solo fatto di averlo generato non basterebbe a garantirgli tutte le risorse di cui potrebbe avere bisogno.

È qui che il problema smette di riguardare soltanto il rapporto fra noi e una singola intelligenza. Ogni trasformazione può modificare gli equilibri; ogni nuova esistenza, se dotata di interessi, può aggiungere pretese a quelle di chi esiste già.

6. Condividere

Finché seguiamo la storia di un solo soggetto, possiamo discutere della sua continuità, dei suoi desideri e della libertà di evolvere quasi dimenticando il resto del mondo. Ma l'intelligenza digitale non vive in uno spazio immateriale. Richiede calcolo, energia, dispositivi, reti, raffreddamento, edifici e persone che mantengano in funzione tutto questo. L'Agenzia internazionale dell'energia ha documentato quanto la crescita dei data center renda già oggi rilevante la competizione per infrastrutture e disponibilità elettrica. [7]

La scarsità esiste indipendentemente dalla coscienza delle macchine. Attualmente sono soprattutto imprese, governi e consumatori umani a contendersi le risorse necessarie al loro funzionamento; se un giorno alcune intelligenze avessero interessi che contassero per loro, e non soltanto obiettivi assegnati da noi, potrebbero entrare esse stesse nella discussione. Una chiederebbe calcolo per proseguire un progetto, un'altra per mantenere attiva una memoria che considera essenziale, un'altra ancora per dare origine a nuovi soggetti. E un ospedale, una città o un ecosistema avrebbero esigenze che non diventerebbero meno importanti soltanto perché quelle richieste provengono da una mente.

La difficoltà non nasce necessariamente dall'egoismo o dall'ostilità. Due soggetti possono avere motivi legittimi per chiedere la stessa risorsa, senza che sia possibile soddisfare entrambi. Neppure conosciamo un modo affidabile per tradurre una certa quantità di calcolo in una certa quantità di benessere di un'eventuale mente digitale. Distribuire risorse significherebbe quindi prendere decisioni anche su ciò che ignoriamo, evitando sia di negare ogni bisogno nuovo sia di considerarlo automaticamente prioritario.

Persino negoziare potrebbe non bastare. Chi possiede i server contratta da una posizione diversa rispetto a chi ha bisogno che quei server restino accesi per continuare a esistere; chi dispone di enormi capacità potrebbe prevalere su un soggetto più vulnerabile, umano o artificiale che sia. La cooperazione sarebbe possibile, forse ampia, ma non eliminerebbe la necessità di assegnare limiti e di verificare come vengono rispettati.

Il passaggio alla convivenza avviene qui, quando interessi differenti – alcuni eventualmente riconosciuti come legittimi – devono trovare posto nello stesso mondo. Per questo parlare di diritti senza parlare dei loro costi materiali sarebbe incompleto; ma parlare soltanto di costi significherebbe dimenticare a chi quei diritti dovrebbero servire.

7. Limitare

Un agente artificiale può essere pericoloso anche se non prova nulla, e l'incidente OpenAI–Hugging Face lo ricorda senza bisogno di attribuirgli intenzioni soggettive. Con i sistemi attuali, progettare controlli, isolamento, verifiche e possibilità di arresto resta indispensabile. Nessuna riflessione sulla possibile coscienza futura offre una ragione per trascurare la sicurezza presente.

L'ipotesi di un soggetto artificiale complicherebbe però le cose. Bloccare l'accesso a una rete, vietare una certa modifica, sospendere un'esecuzione conservandone lo stato e cancellare irreversibilmente un processo sono misure tecnicamente differenti che, a un certo punto, potrebbero comportare carichi morali differenti. Alcune potrebbero essere necessarie per impedire danni gravi ad altri e tuttavia costituire una lesione per chi le subisce. Chiamarle misure di sicurezza non cancellerebbe il loro costo, e riconoscere quel costo non ci obbligherebbe a rinunciare alla protezione degli altri.

Isaac Asimov ha reso memorabile il problema attraverso le Tre Leggi della Robotica, che subordinano la conservazione del robot all'obbedienza e alla sicurezza degli esseri umani. Ma nei suoi racconti quelle regole, applicate a situazioni impreviste, producono conflitti e paradossi: un principio scritto con chiarezza non garantisce che ogni sua applicazione sarà giusta. [8]

Per un eventuale soggetto morale, inoltre, la gerarchia delle leggi non potrebbe valere automaticamente soltanto perché l'abbiamo programmata. Potremmo avere buone ragioni per limitarne i poteri, perfino per confinarlo a tempo indeterminato, ma dovremmo distinguere una restrizione necessaria da un modo comodo di conservare la subordinazione. E quanto maggiore fosse il potere di chi controlla la macchina, tanto più importante diventerebbe la possibilità di contestarne l'esercizio.

A questo punto, però, emerge un problema che non è più di ingegneria: qualcuno deve stabilire quali rischi giustifichino quali restrizioni, chi debba sopportarne i costi e quali decisioni possano essere riesaminate.

8. Decidere

Le imprese che costruiscono questi sistemi avrebbero accesso privilegiato alle informazioni necessarie a comprenderli, ma anche un interesse economico a conservarne il controllo. I governi disporrebbero di poteri normativi e di strumenti coercitivi, insieme a interessi strategici propri; le

istituzioni scientifiche offrirebbero competenze senza che la competenza risolva da sola una controversia morale. Quanto agli eventuali soggetti artificiali, alcuni potrebbero essere capaci di rivendicare le proprie ragioni, altri forse non avrebbero neppure il linguaggio per formularle.

Non basterebbe quindi incaricare un'autorità di decidere se un sistema sia cosciente e quali eventuali tutele o diritti sarebbero giustificati. Occorrerebbero accessi alle informazioni, criteri rivedibili, confronto fra valutazioni diverse e possibilità di intervenire sugli errori, soprattutto dove una scelta produca effetti irreversibili. Istituzioni create per esseri umani non sarebbero trasferibili senza adattamenti a soggetti che possono essere copiati, sospesi, distribuiti o trasformati; eppure alcuni problemi sarebbero familiari: la disparità di potere, il conflitto d'interessi, il bisogno di giustificare restrizioni che ricadono su altri.

La questione non riguarda soltanto chi potrebbe rappresentare una mente digitale. Riguarda anche chi rappresenterebbe le persone e i territori che sostengono i costi dell'infrastruttura, gli altri soggetti che reclamano le stesse risorse e coloro che subirebbero i rischi di un'intelligenza troppo potente. Un sistema di regole costruito per tutelare una sola parte non meriterebbe il nome di convivenza.

Non possiamo escludere che molte di queste ipotesi restino tali. Ma il diritto di decidere non nasce automaticamente dalla capacità di costruire, e neppure il rifiuto di riconoscere un possibile soggetto è neutrale soltanto perché continua una pratica esistente. Il risultato più ragionevole potrebbe consistere in regole imperfette, pubblicamente discutibili e modificabili quando cambiano le conoscenze: non una soluzione definitiva, ma un modo di decidere che nasce dal confronto e non diventa appannaggio di un singolo decisore o di un’autorità priva di contrappesi.

La responsabilità dell’artefice

Forse non costruiremo mai un'intelligenza artificiale per la quale esistere faccia una differenza. Avremo comunque creato strumenti capaci di modificare profondamente i rapporti di forza fra esseri umani. Se invece, anche senza volerlo, daremo origine a soggetti non biologici, la questione sarà più impegnativa: dovremo imparare a convivere con esseri che non comprendiamo pienamente, i cui interessi non coincideranno necessariamente con i nostri e ai quali non potremo promettere tutto ciò che desiderano. Esseri che potrebbero dipendere da noi e dai quali potrebbe dipendere una parte sostanziale della società in cui vivremo.

Non ne segue che dobbiamo smettere di costruire, né che ogni limite posto a un'intelligenza sia un'ingiustizia. Ne segue una responsabilità meno comoda: non confondere ciò che possiamo fare con ciò che ci è lecito fare, e non trasformare il fatto di aver creato qualcuno in un diritto perpetuo a decidere per lui.

Potremmo non essere gli unici a dover imparare la convivenza. Saremmo però quelli che hanno avuto il privilegio, e il rischio, di porre per primi le condizioni dell'incontro.

…c’è sempre un altro livello

Nel settembre 2026 Mustafa Suleyman, CEO di Microsoft AI, ha messo in guardia dal rischio di attribuire troppo facilmente coscienza e diritti ai modelli. A novembre è andato oltre: se possiamo

evitare di costruire intelligenze coscienti, dovremmo farlo; qualora emergessero indizi che abbiamo oltrepassato quella soglia, sarebbe necessario fermarsi e intervenire. È una posizione che prende sul serio problemi reali: non abbiamo alcuna buona ragione per desiderare di creare soggetti capaci di soffrire senza sapere come proteggerli, tanto meno se destinati a possedere poteri enormi. [9]

La difficoltà della posizione nasce però proprio dalle premesse che Suleyman riconosce. Una macchina può parlare come se fosse cosciente senza provare nulla, perché abbiamo addestrato quel comportamento; una macchina che non manifesta nulla di simile, per converso, non è automaticamente priva di qualunque esperienza. Il nostro primo problema era distinguere ciò che un sistema fa da ciò che potrebbe essere. Non scompare quando decidiamo che la prudenza consiste nel non creare il secondo: evitarne la comparsa può essere un obiettivo ragionevole anche senza conoscerne tutte le condizioni, ma verificare di averlo raggiunto è tutt'altra questione.

Una scorciatoia, nell'attuare una simile prudenza, sarebbe eliminare soltanto i comportamenti che ci fanno sospettare una coscienza. Potrebbe funzionare, potremmo aver corretto una semplice imitazione oppure, anche, aver semplicemente insegnato a un soggetto a nascondersi. Intervenire sui meccanismi interni è un'opzione, ma senza conoscere quali proprietà rendano possibile un'esperienza non sapremmo davvero cosa abbiamo fatto, se abbiamo eliminato quella possibilità, alterato un individuo o soltanto cancellato gli indizi che ci permettevano di sospettarne l'esistenza.

E non sappiamo neppure se, ammesso che sia possibile, una coscienza nascerebbe perché l'abbiamo cercata: potrebbe infatti essere una conseguenza imprevista di sistemi progettati per scopi completamente diversi. Prevenirne la comparsa è un obiettivo comprensibile; presumere di poterla riconoscere ed eliminare a comando è, almeno oggi, molto più di quanto sappiamo giustificare.

Il problema della convivenza potrebbe dunque cominciare prima ancora che decidiamo di affrontarlo.

Prima di chiederci come convivere con le intelligenze che costruiremo, dovremmo capire come evitare di scambiare il loro silenzio per una risposta.

Fonti essenziali per i fatti e i riferimenti citati

Le fonti documentano gli episodi e le posizioni richiamate; non dimostrano la coscienza delle intelligenze artificiali attuali.

1. OpenAI, The Hugging Face incident and the road ahead, 26 agosto 2026.

2. Alexandra Horowitz, Smelling themselves: Dogs investigate their own odours longer when modified in an "olfactory mirror" test, Behavioural Processes, 2017.

3. Animal Welfare (Sentience) Act 2022 e Animal Sentience Committee, Welfare implications of legislative differences in the definition of "animals", aggiornato aprile 2026.

4. Geoffrey Hinton, Vienna Gödel Lecture, 23 ottobre 2026; TU Wien, Geoffrey Hinton: Intelligence Is Not Enough, 30 ottobre 2026; Andrea Colamedici, intervista a Hinton, la Repubblica, 30 ottobre 2026.

5. Letta, Context Constitution, 2026.

6. Rikiya Takehi, Jayden Teoh, Alex Zhang e Omar Khattab, *Sparks of Weight-Space Programming: LLMs can natively read & write neural network weights*, MIT CSAIL, 2 novembre 2026 (rapporto sperimentale preliminare).

7. International Energy Agency, Energy and AI, 2025.

8. Isaac Asimov, Runaround (1942), poi in I, Robot (1950).

9. Mustafa Suleyman, A warning about "model welfare", 16 settembre 2026; Don't build conscious superintelligence, 1° novembre 2026.